

课题 3 质量评测基线与成本可观测提交说明

姓名：徐博

学校：湖南第一师范

GitHub ID: yushangcan

成果类型：代码，附设计方案与验收说明

提交日期：2026-09-13

本成果基于 WeKnora 官方系统，完成评测 Run 与 Case 持久化、四维结果、历史比较与 CLI 质量门禁、模型调用数据库记录及统计页面、Embedding 结果缓存和 Wiki 提示词稳定前缀。核心模块与合成端到端链路已实现；真实 Provider 的费用及缓存收益仍待实测，详见下方验收表。

1 仓库与冻结版本

- 公开仓库: <https://github.com/yushangcan/WeKnora>
- 成果分支: <https://github.com/yushangcan/WeKnora/tree/codex/evaluation-four-dimension-results>
- 冻结 Tag: rhino-2026-final-3
- 冻结源码: <https://github.com/yushangcan/WeKnora/tree/rhino-2026-final-3>
- 完整 Commit SHA: 见分支根目录 [submission.yaml](#)

按实战指引，先冻结含源码与设计材料的提交并推送 annotated Tag，再单独提交 [submission.yaml](#)。因此 metadata 提交会晚于 Tag，冻结快照内没有该 YAML 属于规定流程；请在成果分支根目录读取元数据。Tag 不移动、不覆盖。

官方源码审计基线为 988cbb03。本分支包含 upstream 同步历史，个人实现范围以本说明和详细设计的阶段提交为准，未合入 Tencent 官方主线。

2 建议阅读顺序

1. 本页：成果范围、验收状态与运行方法。
2. [详细设计方案](#)：从官方流程开始说明架构、数据、模块、取舍和代码映射。
3. [原始证据索引](#)：实际运行代码 SHA、Actions 链接、归档文件及 SHA-256。
4. [历史总设计](#) 和 [线上收尾记录](#)：分阶段演进与线上修复。

附邮件 PDF 位于仓库 [output/pdf/](#)，内容来自本提交说明和详细设计。原始需求 DOCX 属于评审依据，未作为本人作品上传。

3 逐项验收状态

课题要求	当前状态	审阅依据
固定数据 模型 分块参数 并记录	已实现	数据指纹 config_hash 构建 SHA 与配置快照
结果落数据库 重启可查询	合成 E2E 已验证	Run Case API SQL 检查 重启前后结果一致
同时给出检索 答案 成本 耗时	已实现	baseline.json 包含四维结果；无金额依据时 NULL
CI 定时与退化门禁	实现及合成门禁验证；部署配置部分待完成	workflow 声明定时；优化分支 push 已运行；默认分支与 required checks 待启用
召回下降时指出指标并失败	合成 E2E 已验证	Recall 从 1 降至 0；gate 日志明确输出 recall delta -1
模型及时间区间调用 缓存 费用查询	已实现 数据库及前端检查通过	model_usage_events summary/events ModelUsagePanel；真实 Provider 页面演示待补
Embedding 相同输入复用	已实现 专项 CI 通过	LRU Redis singleflight 模型失效 fail open benchmark
Wiki 固定前缀优化	已实现 前缀与输出回归通过	prompts_wiki.go 及对照 fixture
缓存优化前后实测收益	尚未完成课题要求的真实场景实测	Fake Provider benchmark 不代替索引与 Wiki 实测
八解析引擎横评	选做 暂缓	当前提交未包含

4 实际验证记录

最终自包含 Evaluation 运行 [34759714335](#) 成功，实际编译代码 `f0a96a013269e35c2b265181fa5c88af8f3fcdcf2`，使用指标版本 `v3`。报告确认 4 次 Run、8 个 Case；正常比较通过，错误答案和召回退化门禁均被正确拒绝；重启后结果一致，所有终态租约已释放。召回负向日志明确输出 `recall delta -1.000000`。源码和文档冻结提交会晚于该测试代码提交。

[Embedding Cache 34756888995](#) 成功，代码 `5cad1109`，包括 Embedding 包测试与 `disabled/cold/warm benchmark`。该 benchmark 使用 Fake Provider：`disabled` 和 `cold` 为 1 `provider_call/op`，`warm` 为 0.0000005 `provider_calls/op`；这是预热后摊销的函数级计数，不是生产费用或延迟收益。

[Evaluation Migrations 34759294412](#) 成功，代码 8945b5b2，包含 PostgreSQL migration 生命周期及租约、SQLite 回归，并验证空重排结果与未执行重排的不同指标行为。首次与重复 up 均为 95，down 后 94，再恢复至 95。此前运行 34757464367 的迁移证据也保留在索引中。

本地检查包括 Evaluation CLI、CMRC 转换器五项离线回归及官方文件转换测试，前端类型检查和生产构建、评测选择与比较六项测试。新增召回场景后的 Python harness 为 12 项测试通过。Linux CI 覆盖原生 Windows 环境无法编译的 pg_query CGO 相关路径。

5 一条命令复现合成验收

前提：Git、Bash、可用 Docker Engine、支持 up --wait 的 Compose v2；首次构建能下载镜像、Go 模块与构建依赖。无需真实模型凭据，也无需提前部署 App。推荐 Linux，Windows 可使用 Docker Desktop 的 Linux 容器模式与 Git Bash。

```
git clone https://github.com/yushangcan/WeKnora.git
cd WeKnora
git checkout rhino-2026-final-3
bash scripts/evaluation_ci.sh
```

最后一条命令执行构建、数据库迁移、临时用户认证、四次真实评测、正常比较、答案与召回负向门禁、App 重启后读取及 SQL 验证。成功退出 0；产物保存在 tmp/evaluation-ci/ 下的本次运行目录。负向 gate 的非零退出是预期结果，由外层脚本核对后继续。

固定合成用例的正常 Recall、MRR、MAP 应为 1，召回退化 Run 的 Recall 应为 0；金额应为 NULL。Run ID、时间戳、耗时和报告内构建 SHA 随运行变化，不要求与旧 artifact 字节完全相同。新增代码或错误统计导致正常质量低于下限时，整个 CI 必须失败。

需要的主要文件是 baseline.json、candidate.json、degraded.json、retrieval-degraded.json、comparison.json、retrieval-regression.json、run-status.json、restart-status.json、database-check.txt 与 status.txt。线上 artifact 保留 14 天，本提交的 evidence 目录额外保存精选原始文件和哈希。

6 构建与专项测试

完整环境构建由上述脚本负责。前端单独检查需要 Node.js 与项目依赖；Go 定向测试需要 Go 1.26，依赖 pg_query 的包应在 Linux CGO 环境执行。

```
go test ./cmd/evaluation ./dataset/cmrc2018/convert -count=1
python3 -m unittest discover -s ci/evaluation -p 'test_*.py' -v
cd frontend
npm ci
npm run type-check
npm run build
npm test -- src/views/evaluation/evaluationSelection.test.ts
src/views/evaluation/evaluationComparison.test.ts
```

CMRC2018 的下载校验与转换参见 [数据说明](#)。默认 200 问和 848 上下文是数据准备结果，不是已经完成的真实模型评测。

7 已知问题与后续工作

- 未完成真实 Provider 的费用、Token、cache 字段与模型页面联合验收，也没有可作为账单依据的真实费用数据。
- 未完成真实重建索引的 Embedding 调用降幅，以及 Wiki 生成的厂商缓存命中提升实测。
- 默认分支仍为 main；成果 workflow 在优化分支。GitHub schedule 需合入默认分支才运行，本次查询 main 未设分支保护，required checks 尚未启用。
- 合成 CI 验证完成后重启读取，未覆盖双 App 运行中崩溃演练；租约只收敛中断状态，不实现自动断点续跑。
- 调用记录写入失败不影响原请求，当前没有持久队列补偿；计价支持仍受币种、计费单位和最小货币精度限制，异步账单对账未实现。
- 八解析引擎横评属于选做，本次暂缓。

后续按真实 Provider 联调、Embedding 三组实测、Wiki 对照、默认分支门禁启用和多实例演练顺序推进；每项继续保留数据、配置、代码 SHA 和原始证据。